Predicción de volatilidad en el índice S&P 500 mediante clasificación supervisada

Eduardo Jiménez
Universidad Autónoma de Chihuahua, Facultad de Ingeniería

Octubre de 2026

Resumen

El objetivo de este trabajo es predecir si el índice S&P 500 tendrá alta o baja volatilidad durante un periodo futuro (5 días) de bolsa, por lo tanto está planteado como un problema de clasificación binaria. Los datos son las cotizaciones diarias entre enero de 2007 y julio de 2026, descargadas de Yahoo Finance, utilizando 4 896 días en total. A partir de los precios se construyeron seis variables predictoras y la etiqueta se definió mediante un umbral basado en los datos históricos para determinar si la volatilidad es alta o baja. La división de los datos se hizo por fecha, cuidando que ni la etiqueta, ni el escalado, ni la validación cruzada usaran información del periodo de prueba. Se entrenaron y compararon tres modelos que superaron la referencia de predecir siempre la clase mayoritaria: regresión logística (73.6 %), KNN (72.1 %) y SVM (73.7 %). La prueba de McNemar confirmó que esa ventaja es significativa, pero no encontró diferencias significativas entre los tres modelos, lo que sugiere que pesa más la construcción de las variables que la elección del algoritmo. Por último, al ajustar el umbral de decisión de la regresión logística solo con los datos de entrenamiento, el recall subió de 0.68 a 0.74 sin perder accuracy.

Palabras clave: volatilidad, S&P 500, clasificación supervisada, aprendizaje automático, series temporales, data leakage.

Abstract

The aim of this work is to predict whether the S&P 500 index will show high or low volatility over the next five trading days, so it is framed as a binary classification problem. The data are the daily quotes between January 2007 and July 2026, downloaded from Yahoo Finance, for a total of 4,896 days. Six predictor variables were built from prices and volume, and the label was defined with a threshold based on historical data to decide whether volatility is high or low. The data were split by date, making sure that neither the label, nor the scaling, nor the cross-validation used information from the test period. Three models were trained and compared, and all of them beat the baseline of always predicting the majority class: logistic regression (73.6%), KNN (72.1%) and

SVM (73.7%). McNemar's test confirmed that this advantage is significant, but found no significant differences among the three models, which suggests that feature construction matters more than the choice of algorithm. Finally, tuning the decision threshold of the logistic regression using only the training data raised recall from 0.68 to 0.74 without losing accuracy.

Keywords: volatility, S&P 500, supervised classification, machine learning, time series, data leakage.

1. Introducción

1.1. Contexto

La volatilidad mide qué tanto cambia el precio de un activo. Cuando es alta, los precios presentan movimientos más grandes y existe una mayor incertidumbre sobre su comportamiento futuro [3].

A diferencia de predecir exactamente el precio o su dirección, la volatilidad presenta cierta persistencia, ya que los periodos de mucho movimiento suelen mantenerse durante varios días o semanas, y lo mismo ocurre con los periodos tranquilos. Esta característica permite utilizar información reciente del mercado para intentar predecir su volatilidad futura.

El aprendizaje automático se ha utilizado cada vez más en el análisis financiero, ya que permite encontrar relaciones entre diferentes variables y utilizarlas para realizar predicciones. Existen trabajos que aplican estos métodos específicamente a la volatilidad; por ejemplo, Díaz *et al.* [2] utilizan diferentes modelos para predecir la volatilidad del S&P 500. En el presente trabajo se estará limitando a solo entrenar con un índice y a tomar en cuenta variables registradas en la literatura.

1.2. Objetivos

Objetivo general. Determinar si es posible predecir, con modelos de clasificación supervisada, si el índice S&P 500 tendrá alta o baja volatilidad durante los siguientes cinco días de bolsa.

Objetivos específicos.

1. Descargar y limpiar los datos históricos del índice.
2. Construir las variables y definir la etiqueta sin usar información del futuro.
3. Aplicar una división de datos adecuada para series temporales.
4. Comparar el desempeño de regresión logística, KNN y SVM.
5. Interpretar los resultados de cada modelo.

2. Metodología

2.1. Fuente y características de los datos

Los datos utilizados corresponden al índice S&P 500 y fueron obtenidos de Yahoo Finance mediante la biblioteca yfinance [6]. Se descargaron datos diarios desde el 1 de enero de 2007 hasta el 31 de julio de 2026, identificados por el símbolo ^GSPC. En total se obtuvieron 4 922 días de bolsa, con seis variables por observación: Adj Close, Close, High, Low, Open y Volume. El periodo se seleccionó de manera que incluyera momentos de alta volatilidad, como por ejemplo la crisis financiera de 2008 y la caída registrada en marzo de 2020 por la pandemia. Esto permite contar con suficientes ejemplos de movimientos extremos para el entrenamiento del modelo. La descarga se guardó en un archivo CSV y todo el análisis se hizo sobre él, ya que Yahoo Finance corrige su histórico con el tiempo y una descarga posterior podría cambiar ligeramente los resultados.

En la revisión inicial de los datos no se encontraron valores faltantes, ya que las 4 922 observaciones contaban con información completa en las seis variables. Los valores faltantes aparecieron después durante la construcción de las variables debido a que las ventanas móviles requieren suficientes observaciones previas y a que la volatilidad futura no puede calcularse para los últimos cinco días de la serie. Por esta razón, se eliminaron 26 observaciones, quedando un total de 4 896 registros utilizables.

En cuanto a los valores atípicos, se decidió conservarlos, ya que, como se mencionó, representan periodos de suma importancia para el entrenamiento.

2.2. Construcción de las variables

Se construyeron siete variables a partir de los precios y el volumen, utilizando transformaciones y ventanas temporales similares a las empleadas en trabajos de aprendizaje automático aplicado al S&P 500 [1]. Las seis primeras son las variables de entrada del modelo y la última se usa únicamente para definir la etiqueta.

retorno: Es el cambio porcentual del precio de un día al siguiente, es decir qué tanto subió o bajó el índice ese día. Se obtiene dividiendo el precio de cierre de hoy entre el de ayer y restando uno.

volatilidad_5: Indica qué tanto variaron los retornos durante la última semana de bolsa, así que un valor alto significa que el mercado viene moviéndose mucho. Se obtiene calculando la desviación estándar de la columna retorno sobre una ventana móvil de 5 días. Corresponde a una estimación de volatilidad histórica, ya que utiliza la dispersión de los retornos observados durante una ventana temporal determinada [4].

volatilidad_21: Es lo mismo que la anterior pero mirando hacia atrás un mes completo.

retorno_5: Dice cuánto subió o bajó el precio a lo largo de la última semana, y a diferencia de las medidas de volatilidad aquí sí importa el signo. Se obtiene comparando el precio de cierre de hoy contra el de hace 5 días, en forma de cambio porcentual.

rango_5: Mide qué tan amplio fue el recorrido del precio dentro de cada día, y en promedio durante la última semana. Se obtiene restándole el precio mínimo al máximo

de cada día, dividiendo esa diferencia entre el precio de cierre y promediando el resultado sobre 5 días.

volumen_relativo: Señala si ese día se negoció más o menos de lo normal, ya que un volumen inusualmente alto suele acompañar a los periodos de mayor movimiento. Se obtiene dividiendo el volumen del día entre el promedio del volumen de los últimos 21 días, de modo que un valor de 1 significa un volumen normal y uno de 1.5 significa que se negoció un 50 % más de lo habitual.

volatilidad_futura: Es la desviación estándar de los retornos de los próximos 5 días, aunque esta no entra al modelo como variable de entrada porque es la base de lo que se quiere predecir. Se obtiene calculando la volatilidad de 5 días y luego recorriéndola 5 lugares hacia atrás, de forma que cada fila quede con la volatilidad que le corresponde a sus días siguientes.

Variable a predecir: Se tomó la volatilidad_futura y se comparó contra un umbral:

$$y = \begin{cases} 1 & \text{si la volatilidad de los próximos 5 días} > \text{umbral} \\ 0 & \text{en caso contrario} \end{cases} \tag{1}$$

El umbral es la mediana de la variable volatilidad_5 durante el periodo de entrenamiento, y su valor resultó 0.00757. Un detalle importante es que se calculó solo con los datos de entrenamiento porque si se hubiera usado la mediana de toda la serie, la definición misma de la etiqueta habría incorporado información del periodo de prueba, lo cual es una forma de data leakage.

El reparto final quedó en 51.8 % de días de volatilidad alta contra 48.2 % de volatilidad baja, suficientemente parejo como para no tener que aplicar ninguna técnica de balanceo.

2.3. Análisis de las nuevas variables

La Figura 1 muestra la correlación de Pearson entre todas las variables, incluida la volatilidad futura y la etiqueta.

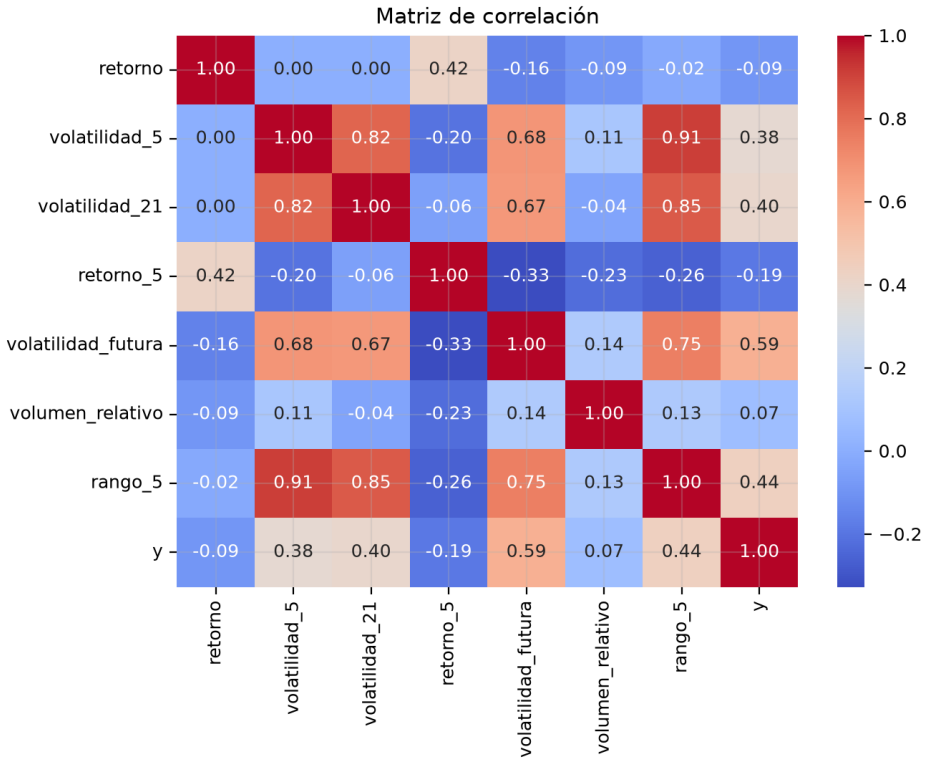


Figura 1: Matriz de correlación entre las variables construidas, la volatilidad futura y la etiqueta.

Hay un bloque claro formado por las tres medidas de volatilidad, que se correlacionan fuertemente entre sí. El caso más marcado es volatilidad_5 con rango_5, en 0.91, lo cual era esperable porque ambas capturan cuánto se movió el precio. Frente a la volatilidad futura, la variable más relacionada es el rango diario (0.75) y la que menos el volumen relativo (0.14).

La Figura 2 muestra los retornos diarios a lo largo de los casi veinte años de la muestra. Los movimientos grandes no están repartidos de manera pareja, se juntan en ciertas épocas y en otras el mercado apenas se mueve. La Figura 3 deja ver lo mismo con más claridad, graficando directamente la volatilidad calculada sobre ventanas de 21 días (volatilidad_21), se observa que esta no salta de un día para otro: sube y se queda alta durante semanas, luego baja y se mantiene ahí. Los dos picos que dominan la gráfica son la crisis de 2008 y marzo de 2020.

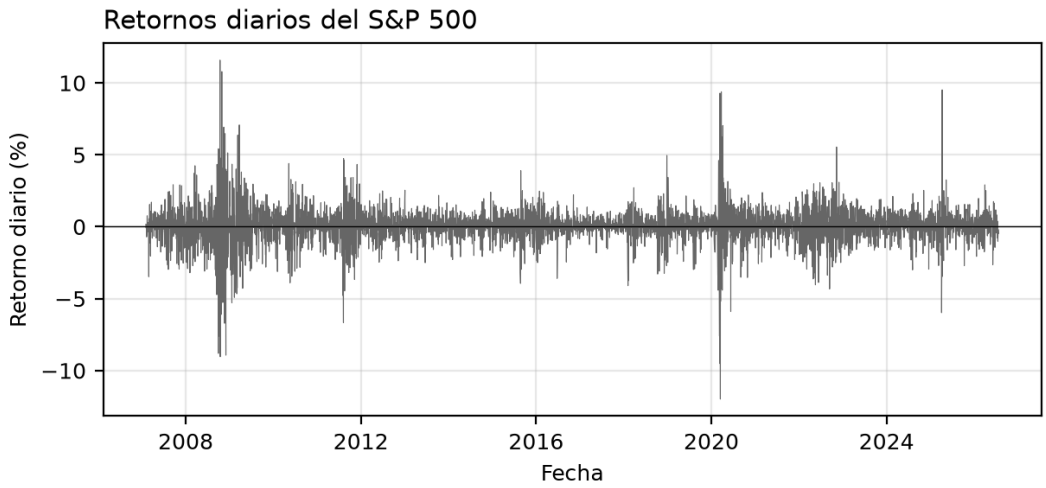


Figura 2: Retornos diarios del S&P 500 entre 2007 y 2026.

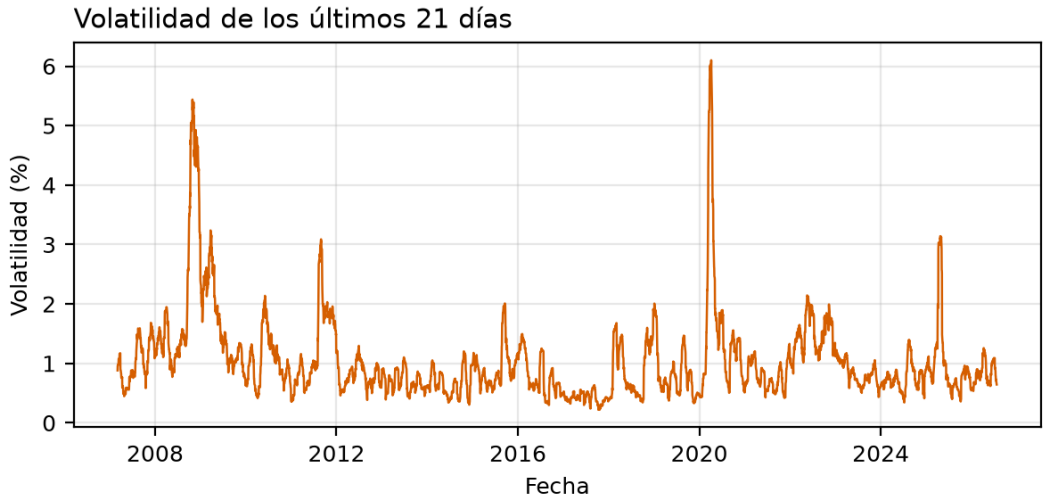


Figura 3: Volatilidad del S&P 500 medida como desviación estándar de los retornos de los últimos 21 días.

2.4. Entrenamiento de modelos

Con series temporales no se puede dividir al azar ya que hacerlo significaría entrenar el modelo con datos posteriores a los que luego se le pide predecir, y el resultado saldría artificialmente bueno. La división se hizo por fecha, con aproximadamente 80 % para entrenamiento y 20 % para prueba:

- **Entrenamiento**: febrero de 2007 al 23 de diciembre de 2021 (3 751 días).
- **Prueba**: enero de 2022 a julio de 2026 (1 140 días).

Los últimos cinco días de 2021 se dejaron fuera, ya que su etiqueta se calcula con retornos de enero de 2022, que pertenecen a la prueba. Es importante aclarar que la fecha no entra como variable al modelo. Se usa únicamente para ordenar los datos y separarlos.

Antes de entrenar hubo que estandarizar las variables, porque KNN y SVM funcionan calculando distancias y aquí las escalas eran muy distintas, ya que la volatilidad de 5 días se mueve alrededor de 0.007 mientras que el volumen relativo ronda el 1. Para eso se usó StandardScaler de scikit-learn [5], ajustándolo solo con los datos de entrenamiento para que la información del periodo de prueba no se filtrara.

El desempeño durante el entrenamiento se midió con validación cruzada usando TimeSeriesSplit de 5 particiones, que respeta el orden cronológico a diferencia de la validación cruzada normal que reparte las observaciones al azar. También se le puso el parámetro gap en 5, porque la etiqueta de cada día se construye con los cinco días siguientes y sin ese hueco los bloques se traslaparían. Los hiperparámetros de los tres modelos se fijaron a mano después de probar algunos valores.

- **Regresión logística.** Es el modelo más simple y sirve como referencia, además de que permite leer el peso de cada variable. Se configuró con C en 0.1, que controla la regularización, y obtuvo 0.7363 de accuracy promedio en validación cruzada.
- **KNN.** Clasifica cada día según los días históricos que más se le parecen. Se configuró con 55 vecinos, que es un valor alto y se eligió así porque con pocos vecinos el modelo se vuelve muy sensible al ruido, y obtuvo 0.7402, siendo el mejor de los tres en esta etapa.
- **SVM.** Busca la frontera que mejor separa las dos clases. Se configuró con kernel rbf, que permite fronteras curvas, con C en 0.1 y gamma en scale. Obtuvo 0.6890.

El SVM no solo quedó último sino que además fue el más disparejo, dado que uno de sus pliegues bajó hasta 0.4528 mientras que otro llegó a 0.8480, lo cual sugiere que su desempeño depende mucho del periodo que le toque evaluar. Las métricas que se reportan al final son accuracy, precision, recall y F1-score, junto con la matriz de confusión de cada modelo, intervalos de confianza para el accuracy y la prueba de McNemar para comparar los modelos entre sí.

3. Resultados y discusiones

La Tabla 1 recoge el desempeño de los tres modelos sobre el conjunto de prueba.

Tabla 1: Resultados en el conjunto de prueba.

Métrica	Regresión Logística	KNN	SVM
Accuracy	0.7360	0.7211	0.7368
Precision	0.8258	0.8239	0.8262
Recall	0.6795	0.6487	0.6810
F1-score	0.7456	0.7259	0.7466

Para saber si estos números son buenos hay que compararlos contra algo, y la referencia más simple es predecir siempre la clase más frecuente, que en el conjunto de prueba da un accuracy de 56.9 %. La Figura 4 muestra los tres modelos frente a esa línea, con intervalos

de confianza del 95 % obtenidos con bootstrap por bloques de 21 días [8], que conserva la dependencia entre días consecutivos.

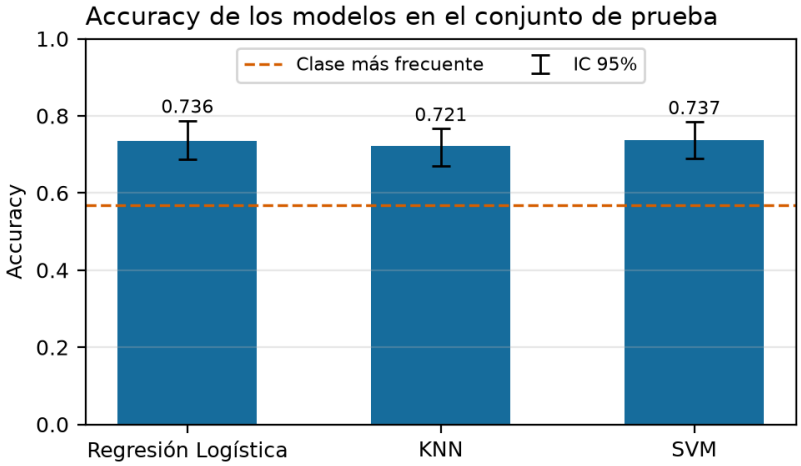


Figura 4: Accuracy de los tres modelos frente a la referencia de predecir siempre la clase más frecuente. Las barras de error son intervalos de confianza del 95 %.

Los tres superan la referencia por unos 16 puntos porcentuales, así que las variables construidas sí contienen información útil, y sus intervalos de confianza, aunque se enciman entre sí, quedan muy por encima de esa línea. Ahora bien, entre ellos las diferencias son mínimas, ya que el SVM obtiene 73.68 % y la regresión logística 73.60 %, o sea ocho centésimas de diferencia sobre 1 140 días, que equivale a un solo acierto más en el total. Con esa distancia no se puede sostener que un modelo sea mejor que el otro, y KNN queda algo más atrás con 72.11 %.

Para comprobarlo se aplicó la prueba exacta de McNemar [7, 9], que solo toma en cuenta los días en que un modelo acierta y el otro no. Entre la regresión logística y el SVM hay 71 días así, 35 contra 36, de modo que el empate no se debe a que clasifiquen igual sino a que sus diferencias se compensan. La Tabla 2 muestra todas las comparaciones.

Tabla 2: Prueba de McNemar entre pares de modelos y contra la referencia.

	Solo el primero	Solo el segundo	p-valor
Regresión Logística vs SVM	35	36	1.0000
Regresión Logística vs KNN	63	46	0.1250
KNN vs SVM	30	48	0.0535
Regresión Logística vs Referencia	398	208	< 0.0001
KNN vs Referencia	401	228	< 0.0001
SVM vs Referencia	398	207	< 0.0001

Los tres modelos le ganan a la referencia con p-valores prácticamente nulos, mientras que entre ellos ninguna diferencia es significativa ($p > 0.05$). La prueba supone días independientes y aquí no lo son del todo, porque las etiquetas de días seguidos comparten cuatro de sus cinco días, así que sus p-valores salen algo optimistas, lo que refuerza que no hay un ganador.

Es importante señalar algo que aparece en la validación cruzada. El SVM tuvo ahí el peor promedio de los tres, 68.90 %, con una desviación estándar de 0.134 e incluso llegó a caer hasta 45 %.

La Figura 5 muestra las tres matrices y la Tabla 3 las desglosa para poder compararlas.

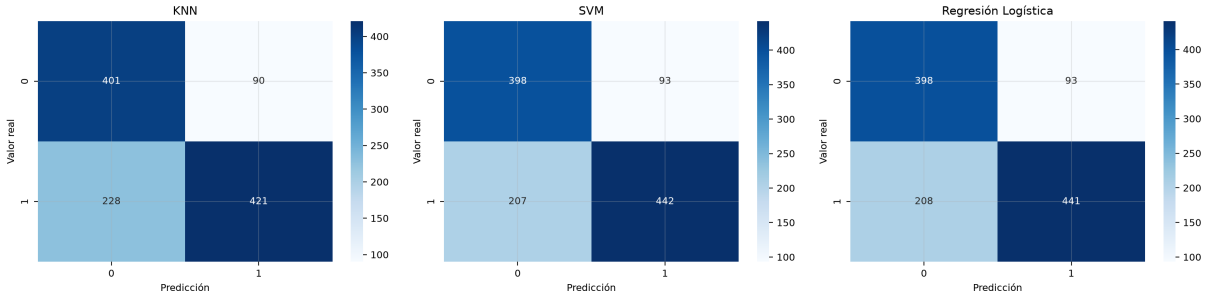


Figura 5: Matrices de confusión de los tres modelos sobre el conjunto de prueba. La clase 0 corresponde a volatilidad baja y la 1 a volatilidad alta.

Tabla 3: Desglose de la matriz de confusión de cada modelo.

	Regresión Logística	KNN	SVM
Verdadero negativo	398	401	398
Falso positivo	93	90	93
Falso negativo	208	228	207
Verdadero positivo	441	421	442

Aquí aparece un detalle que la tabla de métricas no deja ver, porque KNN es el modelo con menos falsos positivos de los tres con 90 frente a los 93 de los otros dos, pero también es el que más falsos negativos comete con 228 frente a los 207 del SVM. Eso importa dado que los dos errores no cuestan lo mismo, ya que un falso negativo deja a un inversionista sin protección justo cuando la necesita mientras que un falso positivo solo significa haber sido precavido de más. Así que KNN gana en la casilla barata y pierde en la cara.

Lo que comparten los tres es la dirección del error, porque aciertan más del 82 % de las veces que anuncian volatilidad alta pero solo detectan alrededor de dos tercios de los episodios.

Parte de ese recall bajo se explica por el reparto de clases: la volatilidad alta pasó del 50.2 % de los días en entrenamiento al 56.9 % en prueba, pero los modelos la anuncian en cerca del 47 % de los días, así que se quedan cortos.

Como el error caro es el falso negativo, se ajustó el umbral de decisión de la regresión logística, que empató con el SVM ($p = 1$), es más simple y da probabilidades directamente. Por defecto el modelo anuncia volatilidad alta cuando la probabilidad pasa de 0.5; si ese corte se baja, avisa más seguido, sube el recall y aumentan las falsas alarmas. Este umbral no es el de la etiqueta (0.00757), y para no caer en otra forma de data leakage se eligió solo con entrenamiento: con las probabilidades de los pliegues de validación del mismo TimeSeriesSplit se tomó el umbral que maximiza el F1-score, que resultó 0.43. La Figura 6 muestra la curva precision-recall en el conjunto de prueba con los dos puntos de operación, que la Tabla 4 compara.

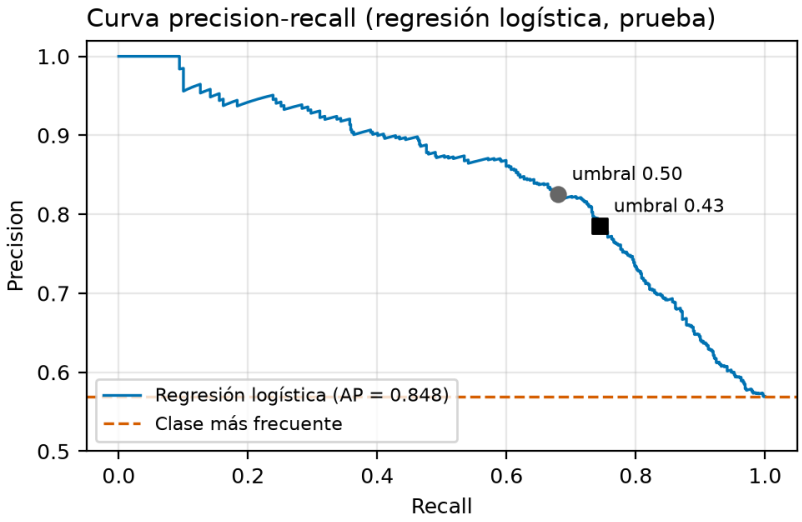


Figura 6: Curva precision-recall de la regresión logística en el conjunto de prueba, con el umbral por defecto (0.50) y el ajustado con entrenamiento (0.43).

Tabla 4: Regresión logística con el umbral de decisión por defecto y con el ajustado.

Métrica	Umbral 0.50	Umbral 0.43
Accuracy	0.7360	0.7386
Precision	0.8258	0.7854
Recall	0.6795	0.7442
F1-score	0.7456	0.7642
Falsos negativos	208	166
Falsos positivos	93	132

Con 0.43 el modelo detecta 42 días de volatilidad alta más a cambio de 39 falsas alarmas más, es decir, cambia errores caros por baratos casi uno a uno sin que baje el accuracy, y anuncia volatilidad alta en el 53.9 % de los días en lugar del 46.8 %.

Para saber qué variables pesan más se pueden revisar los coeficientes de la regresión logística, porque al trabajar sobre variables estandarizadas se pueden comparar entre sí.

Tabla 5: Coeficientes de la regresión logística.

	Coeficiente
Retorno 5 días	-0.419
Volatilidad 5 días	-0.319
Retorno diario	-0.287
Volumen relativo	0.000
Volatilidad 21 días	0.947
Rango diario promedio	1.885

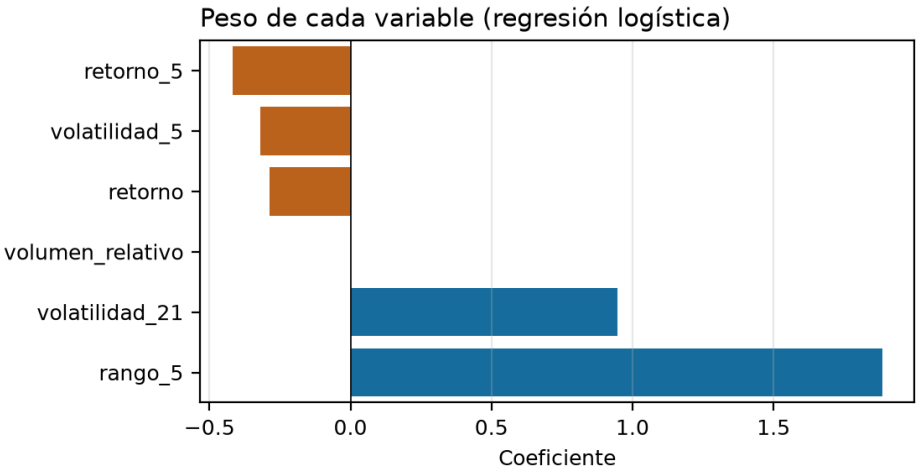


Figura 7: Coeficientes de la regresión logística sobre variables estandarizadas.

El rango diario promedio domina con 1.885, seguido de la volatilidad de 21 días con 0.947, y los dos son positivos, lo cual concuerda con la Figura 3 porque si el mercado viene moviéndose mucho lo más probable es que siga haciéndolo. El volumen relativo resulta casi irrelevante con un coeficiente prácticamente nulo (0.000) y además era la variable menos correlacionada con la volatilidad futura, así que los dos diagnósticos coinciden.

Que volatilidad_5 aparezca con coeficiente -0.319 resulta contraintuitivo porque es una medida de volatilidad y uno esperaría que empujara hacia la clase alta, pero la explicación está en la Figura 1 ya que esa variable correlaciona 0.91 con rango_5 y 0.82 con volatilidad_21. Cuando dos predictores contienen prácticamente la misma información entonces la regresión reparte el peso entre ellos de forma inestable y los signos individuales dejan de ser interpretables uno por uno, de manera que lo correcto es leer el bloque de volatilidad en conjunto, donde el efecto neto es claramente positivo.

4. Conclusiones

Sí se puede anticipar con cierto acierto si el S&P 500 tendrá alta o baja volatilidad en los siguientes cinco días, ya que los tres modelos rondaron el 73 % de accuracy frente al 56.9 % de la referencia, lo que confirma que los datos históricos guardan información aprovechable, y la prueba de McNemar indica que esa ventaja es significativa ($p < 0.0001$).

Las diferencias entre los tres fueron muy pequeñas y ninguna resultó significativa ($p > 0.05$); entre los dos mejores fue de un solo acierto en el total, así que el modelo más simple igualó al más complejo y eso sugiere que aquí pesa más la construcción de las variables que la elección del algoritmo. En cuanto a esas variables, el rango diario promedio y la volatilidad de 21 días son las que más influyen mientras que el volumen relativo resultó prácticamente inútil.

Sobre los errores, los tres modelos fallan por el mismo lado porque aciertan cuando anuncian volatilidad alta pero dejan pasar cerca de un tercio de los episodios sin avisar, que es el error de mayor coste práctico, de modo que mejorar el recall sería la prioridad si el modelo tuviera que usarse de verdad. Un primer paso en esa dirección fue bajar el umbral de decisión a 0.43, elegido solo con entrenamiento, con lo que el recall subió de

0.68 a 0.74 sin perder accuracy.

Entre las limitaciones están que solo se analizó un índice, con un periodo de prueba de poco más de cuatro años y datos diarios; que el modelo dice si la volatilidad será alta o baja pero no qué tan alta; que los hiperparámetros se fijaron a mano, y que no se evaluó ninguna estrategia de inversión. Como trabajo futuro se propone repetir el procedimiento con otros índices, agregar variables como el VIX, probar modelos de ensamble como Random Forest y buscar los hiperparámetros de forma sistemática con la misma validación cruzada.

Referencias

[1] S. Choi et al., "A machine learning approach to predict the S&P 500 absolute percent change," *Discover Artificial Intelligence*, 2024. doi: 10.1007/s44163-024-00104-9.

[2] J. D. Díaz, E. Hansen, and G. Cabrera, "Machine-learning stock market volatility: Predictability, drivers, and economic value," *International Review of Financial Analysis*, vol. 94, 103286, 2024. doi: 10.1016/j.irfa.2024.103286.

[3] Corporate Finance Institute, "Volatility," 2019. [En línea]. Disponible en: `https://corporatefinanceinstitute.com/resources/career-map/sell-side/capital-markets/volatility-vol/`

[4] Corporate Finance Institute, "Historical Volatility (HV)," 2020. [En línea]. Disponible en: `https://corporatefinanceinstitute.com/resources/career-map/sell-side/capital-markets/historical-volatility-hv/`

[5] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[6] A. Aroussi, "yfinance: Yahoo! Finance market data downloader," Python package, [En línea]. Disponible en: `https://github.com/ranaroussi/yfinance`

[7] Q. McNemar, "Note on the sampling error of the difference between correlated proportions or percentages," *Psychometrika*, vol. 12, no. 2, pp. 153–157, 1947. doi: 10.1007/BF02295996.

[8] H. R. Künsch, "The jackknife and the bootstrap for general stationary observations," *The Annals of Statistics*, vol. 17, no. 3, pp. 1217–1241, 1989. doi: 10.1214/aos/1176347265.

[9] S. Seabold and J. Perktold, "statsmodels: Econometric and statistical modeling with Python," in *Proc. 9th Python in Science Conference*, 2010, pp. 92–96. doi: 10.25080/Majora-92bf1922-011.